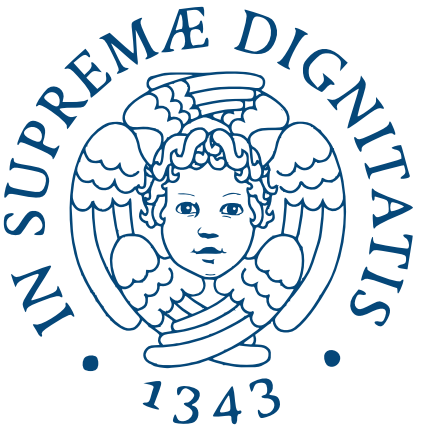


UNIVERSITÀ DI PISA

DIPARTIMENTO DI INGEGNERIA DELL'INFORMAZIONE

Corso di laurea triennale in Ingegneria Biomedica

Riconoscimento automatico dello stato emotivo tramite analisi di segnali elettroencefalografici

Relatore:
Catrambone Vincenzo

Candidata:
Erica Ginevri

Anno Accademico 2024/2025

I Introduzione

Le emozioni rappresentano una componente fondamentale dell'esperienza umana: influenzano le decisioni, modulano il comportamento e si riflettono in precise risposte fisiologiche. Quando il cervello percepisce uno stimolo emotivo, esso genera cambiamenti nell'attività neuronale, modulando l'attivazione di diverse aree cerebrali e producendo risposte corporee osservabili, come variazioni nella frequenza cardiaca o nell'attività elettrica cerebrale. Queste risposte fisiologiche costituiscono una finestra preziosa per comprendere come le emozioni si manifestano all'interno del sistema nervoso. In particolare, l'elettroencefalogramma (EEG) consente di registrare l'attività elettrica del cervello in maniera non invasiva, fornendo informazioni dettagliate sui processi neuronali che si verificano in risposta a stimoli emozionali.

Per rappresentare e classificare le emozioni, uno dei modelli più diffusi è il *modello bidimensionale valence–arousal* riportato in Figura 1. Esso descrive ogni stato emotivo in base a due dimensioni: la *valence*, che riflette la piacevolezza percepita di uno stimolo (positiva, neutra o negativa), e l'*arousal*, che misura il grado di attivazione fisiologica associato (basso o alto).

Ogni esperienza emotiva può quindi essere descritta da una combinazione di valence e arousal: ad esempio, uno stimolo può essere piacevole e altamente attivante (come una risata), spiacevole e altamente attivante (come un rumore improvviso), oppure neutro e poco attivante (come un oggetto comune). Questo modello consente dunque di rappresentare in modo quantitativo e comparabile gli stati emotivi indotti da stimoli di natura diversa.

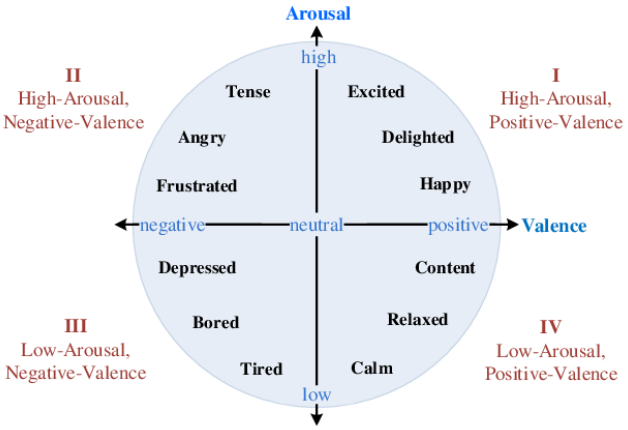


Figura 1: Modello bidimensionale valence–arousal.

Per interpretare in modo sistematico le informazioni contenute nei segnali EEG è necessario ricorrere a tecniche di *machine learning*, capaci di individuare schemi complessi e trasformare osservazioni qualitative in classificazioni oggettive. In particolare, questo lavoro affronta un problema di *classificazione multiclasse*, in cui l'obiettivo è distinguere automaticamente lo stato emotivo dei soggetti a partire dall'attività cerebrale registrata durante la visione di immagini appartenenti a tre categorie: positive, negative e neutre. Dai segnali EEG sono state estratte caratteristiche quantitative nelle principali bande di frequenza e organizzate in forma matriciale per l'analisi automatica. La classificazione è stata condotta con l'algoritmo *K-Nearest Neighbors (KNN)*, scelto per la sua capacità di discriminare pattern multidimensionali, mentre la *Principal Component Analysis (PCA)* è stata impiegata per ridurre la dimensionalità e valutare l'impatto della selezione delle feature sulle prestazioni del modello.

In sintesi, il presente lavoro combina l'analisi quantitativa dei segnali EEG e metodi di machine learning per classificare le risposte emotive in maniera riproducibile. Questo approccio non solo consente di ottenere una distinzione automatica tra categorie di immagini, ma offre anche indicazioni sulle bande di frequenza maggiormente coinvolte nella percezione degli stimoli emotivi.

II Materiali e metodi

A. Descrizione del dataset

L'esperimento è stato condotto in conformità con la Dichiarazione di Helsinki e approvato dal comitato etico locale (Protocollo no. 3727). All'esperimento hanno partecipato 35 soggetti dell'Università di Padova, con età media di 22,5 $\pm$ 2,4 anni. Tutti hanno fornito il consenso informato e hanno ricevuto un compenso di 15 euro. Ai partecipanti è stato richiesto di astenersi dal consumo di alcolici il giorno precedente alla sessione sperimentale e di non assumere stimolanti (come caffeina e nicotina) nel giorno dell'esperimento [1].

L'esperimento si è svolto in una stanza insonorizzata e a illuminazione ridotta dove i partecipanti erano seduti comodamente mentre veniva registrato l'EEG. Prima del compito principale, ogni soggetto ha eseguito prove di pratica per familiarizzare con la procedura.

Il compito consisteva nella visione di un totale di 72 immagini digitali a colori per soggetto, selezionate dall' *International Affective Picture System (IAPS)* [2]. Le immagini sono state suddivise in tre categorie emotive: positive, negative e neutre, definite in base ai valori di valence e arousal. La Tabella 1 riporta le caratteristiche principali delle tre tipologie di immagini.

Ogni trial sperimentale seguiva la sequenza mostrata in Figura 2: (i) croce di fissazione bianca per 3 secondi; (ii) visualizzazione dell'immagine per 6 secondi; (iii) nuova croce di fissazione bianca per un intervallo compreso tra 6 e 8 secondi.

Tipo di immagine	Esempi	Valence	Arousal
Positiva	volti sorridenti, bambini che giocano	positiva	alto
Neutra	oggetti domestici	neutra	basso
Negativa	attacchi di animali	negativa	alto

Tabella 1: Descrizione delle tipologie di immagini presentate ai soggetti.

Le immagini sono state presentate in ordine semi-casuale, in modo da evitare che stimoli della stessa categoria emotiva comparissero consecutivamente.

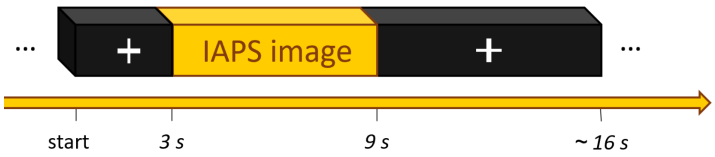


Figura 2: Sequenza temporale di presentazione delle immagini.

Durante l'esperimento, il segnale EEG è stato acquisito tramite una cuffia flessibile con 32 elettrodi posizionati secondo il sistema internazionale 10–20, con riferimento online a CPz. L'impedenza dei canali è stata mantenuta al di sotto di 10 kΩ e la frequenza di campionamento utilizzata era pari a 1000 Hz.

B. EEG preprocessing

Le registrazioni EEG sono state preprocessate con *MATLAB R2023b* (The MathWorks Inc., Natick, MA, USA) e il toolbox *EEGLAB* [3]. I segnali sono stati sottocampionati a 500 Hz, ri-referenziati ai mastoidi, filtrati in banda [4−45] Hz e ripuliti dagli artefatti tramite l'analisi ICA.

C. Estrazione delle caratteristiche

Completata la fase di preprocessing, per ciascun canale EEG è stata calcolata la *Power Spectral Density (PSD)* tramite trasformata di Fourier con la finestra di Hamming. L'analisi è stata condotta utilizzando una finestra temporale mobile di 2s con passo di 0.25s, ottenendo uno spettrogramma campionato a 4Hz nel dominio del tempo e a 0.5Hz nel dominio della frequenza. In sintesi, per ciascun soggetto, immagine e canale, sono stati estratti i valori medi della PSD nelle quattro bande di frequenza: θ (4−8 Hz), α (8−12 Hz), β (12−30 Hz) e γ (30−45 Hz).

D. Preparazione dei dati per la classificazione

Le caratteristiche ottenute sono state salvate in una matrice 3D di dimensioni $2468 \times 4 \times 30$: la prima dimensione corrisponde al numero totale di trial (immagini viste da tutti i soggetti), la seconda alle 4 bande EEG e la terza ai 30 canali. Il numero totale teorico di trial sarebbe pari a 2520 (35 soggetti × 72 immagini ciascuno); tuttavia, 52 trial sono stati esclusi a causa di artefatti, ottenendo così un dataset finale di 2468 trial validi.

Per consentire una corretta classificazione, la matrice è stata riorganizzata in formato 2D (2468×120) come mostrato in Figura 3, e il *vettore target* (2468×1) è stato creato assegnando il valore 1 alle immagini positive, 2 alle immagini neutre e 3 alle immagini negative.

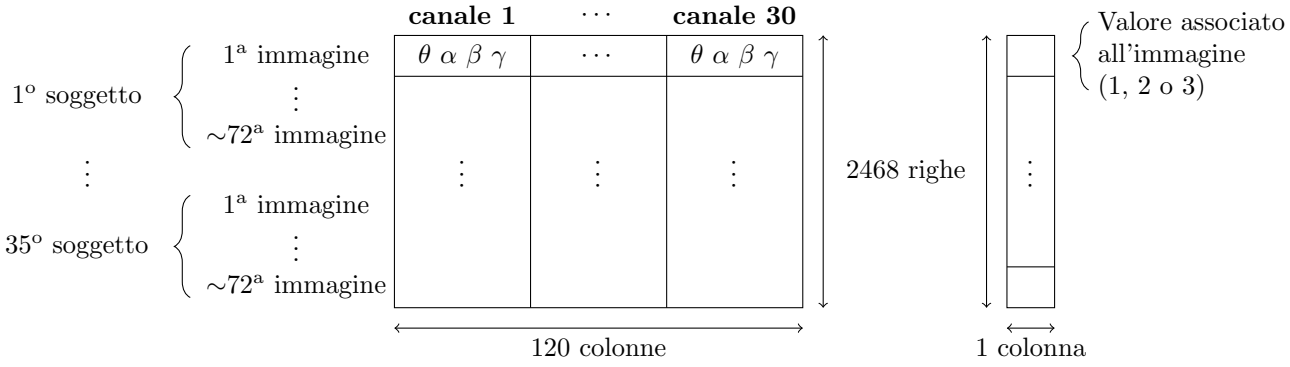


Figura 3: Struttura della matrice 2D con 2468 righe (= 35 soggetti × ∼ 72 immagini) e 120 colonne (30 canali EEG × 4 bande) affiancata al vettore target con 2468 righe e 1 colonna contenente i valori associati alla tipologia di immagine vista.

E. Procedura di classificazione

Fasi del processo di classificazione La classificazione degli stati emotivi ha l'obiettivo di assegnare a ciascun campione EEG la categoria corrispondente alla tipologia di immagine visualizzata (positiva, neutra o negativa). Il processo si articola in due fasi principali: durante l'addestramento (*training*), il modello memorizza i campioni etichettati del dataset, che fungono da punti di riferimento nello spazio delle caratteristiche; durante la fase di test, ciascun nuovo campione viene confrontato con questi punti per identificare la classe più appropriata. In questo modo, il modello utilizza le informazioni apprese dai dati di training per classificare correttamente nuovi esempi, basandosi sulla similarità tra caratteristiche dei segnali EEG.

Algoritmo KNN Per realizzare la classificazione è stato adottato l'algoritmo *K-Nearest Neighbors (KNN)*, un metodo supervisionato che assegna a un nuovo campione la classe più frequente tra i k esempi più vicini, calcolando la distanza (in questo lavoro, euclidea) nello spazio delle caratteristiche. Essendo un algoritmo non parametrico e basato sugli esempi, il KNN non costruisce un modello esplicito durante l'addestramento, ma prende decisioni confrontando direttamente i nuovi dati con quelli di training già etichettati [4]. In particolare, è stata utilizzata la variante *Fine KNN*, corrispondente a $k = 1$. In questo caso, ogni nuovo campione viene classificato in base al singolo esempio più vicino nel dataset di training. Tale approccio consente di catturare differenze sottili nei segnali EEG, ma rende il modello più sensibile al rumore intrinseco dei dati.

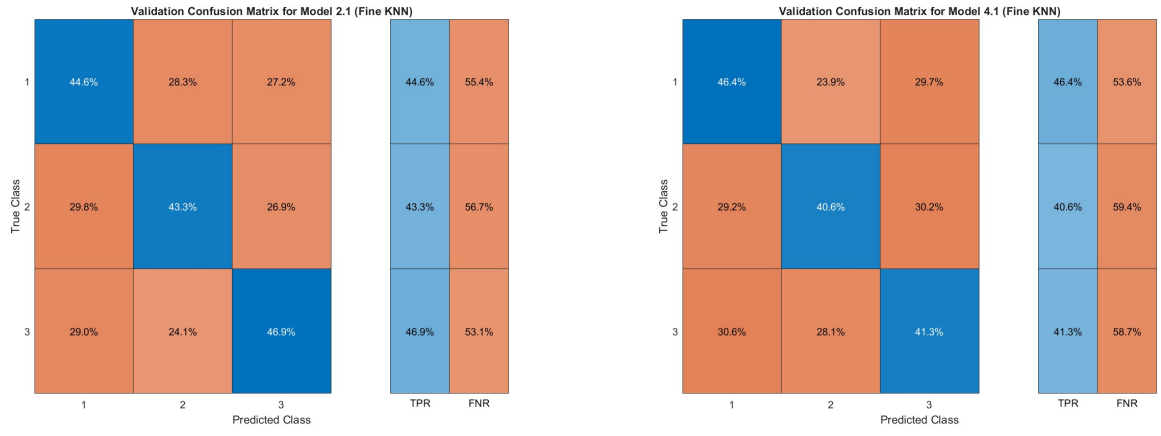
5 fold cross-validation Per ottenere una stima robusta delle prestazioni del classificatore è stata applicata la procedura di *5-fold cross-validation*. Il dataset è stato suddiviso in cinque sottoinsiemi di dimensioni simili: in ciascun ciclo, quattro sottoinsiemi sono stati utilizzati per addestrare il modello e il quinto per testarlo. L'operazione è stata ripetuta cinque volte, in modo che ogni sottoinsieme fungesse da test set una volta. L'accuratezza finale è stata calcolata come media dei cinque test, garantendo una valutazione più affidabile e meno soggetta alla casualità di una singola suddivisione dei dati.

F. Selezione delle caratteristiche

Per valutare se la riduzione della dimensionalità potesse migliorare le prestazioni del classificatore, è stata applicata la *Principal Component Analysis (PCA)*. In particolare, i dati originali con 120 feature (30 canali $\times$ 4 bande) sono stati proiettati in uno spazio ridotto di 50 componenti principali, selezionate per catturare la maggior parte della varianza complessiva.

III Risultati

I risultati ottenuti, con e senza l'applicazione della PCA, sono illustrati attraverso le matrici di confusione mostrate rispettivamente in Figura 4a e Figura 4b.



(a) Classificazione senza PCA (accuracy = 44.9%)

(b) Classificazione con PCA (accuracy = 42.8%)

Figura 4: Matrici di confusione ottenute applicando l'algoritmo di classificazione Fine KNN.

Le matrici di confusione permettono di analizzare in dettaglio le prestazioni del classificatore. In esse, ogni riga rappresenta la classe reale dell'immagine (positiva, neutra o negativa), mentre ogni colonna rappresenta la classe prevista dal modello. Le celle sulla diagonale principale indicano le immagini correttamente classificate,

mentre le celle fuori diagonale mostrano gli errori di classificazione: ad esempio, una cella in riga "positiva" e colonna "negativa" indica quante immagini positive sono state erroneamente classificate come negative.

Questo tipo di rappresentazione fornisce più informazioni rispetto alla sola accuratezza complessiva, poiché permette di individuare quali classi vengono confuse tra loro e quali sono invece distinguibili in maniera più affidabile dal modello.

IV Discussione

I risultati ottenuti mostrano che il classificatore Fine KNN ha raggiunto un'accuratezza complessiva del 44.9% senza PCA e del 42.8% con PCA, valori superiori alla soglia casuale (33.3%) ma comunque limitati rispetto a quello che è il massimo raggiungibile.

Analisi delle matrici di confusione Le matrici di confusione rivelano che alcune classi emotive vengono confuse più frequentemente di altre. In particolare, le immagini neutre mostrano una tendenza ad essere classificate erroneamente come positive o negative, indicando che il modello ha difficoltà a distinguere stimoli a bassa attivazione fisiologica rispetto a quelli più emozionanti. Questo evidenzia la presenza di pattern EEG sovrapposti tra alcune categorie, rendendo la classificazione più complessa.

Effetto della PCA L'applicazione della PCA con 50 componenti principali non ha migliorato le prestazioni. Ciò suggerisce che le informazioni discriminanti sono distribuite tra le feature originali e che una riduzione lineare della dimensionalità non sia sufficiente a preservarle.

V Conclusione

Questo lavoro ha esplorato la possibilità di classificare automaticamente stati emotivi a partire dall'attività cerebrale registrata tramite EEG. L'approccio basato su caratteristiche spettrali e classificazione con Fine KNN ha consentito di ottenere risultati superiori al caso, evidenziando la presenza di pattern neurali associabili agli stati emotivi. Tuttavia, l'accuratezza raggiunta rimane limitata e non ancora sufficiente per un impiego applicativo, a causa della natura rumorosa dei segnali EEG, della forte variabilità inter-soggetto e della dimensione ridotta del dataset.

Tra le prospettive di miglioramento, particolare rilevanza assume la validazione *Leave-One-Subject-Out (LOSO)*, che consiste nell'addestrare il modello su tutti i soggetti tranne uno e nel testarlo sul soggetto escluso, ripetendo la procedura per ciascun partecipante. Questa strategia, più stringente rispetto alla cross-validation convenzionale, permetterebbe di valutare con maggiore realismo la capacità di generalizzazione del sistema a nuovi individui, condizione essenziale per una futura applicazione pratica.

Inoltre, l'impiego di tecniche di riduzione della dimensionalità non lineari e di classificatori più avanzati (ad esempio SVM o modelli di deep learning) potrebbe incrementare la sensibilità del sistema ai pattern EEG rilevanti, riducendo al contempo l'impatto del rumore. Anche la raccolta di dataset più ampi, bilanciati e diversificati si presenta come un passo fondamentale per aumentare l'affidabilità del riconoscimento.

In conclusione, il presente studio fornisce un contributo metodologico replicabile e una base solida per sviluppi futuri nel campo del riconoscimento affettivo basato su EEG, con potenziali applicazioni in ambito clinico, educativo e neurotecnologico.

Riferimenti bibliografici

[1] V. Catrambone, F. Mura, E. Patron, C. Gentili and G. Valenza, *Impaired functional brain-heart interplay sustains depressive symptomatology*, bioRxiv 2024.03.14.585023; doi: https://doi.org/10.1101/2024.03.14.585023

[2] P. Lang and M. M. Bradley, *The international affective picture system (IAPS) in the study of emotion and attention*, Handbook of emotion elicitation and assessment, vol. 29, pp. 70-73, 2007.

[3] A. Delorme and S. Makeig, *EEGLAB: an open source toolbox for analysis of single-trial eeg dynamics including independent component analysis*, Journal of neuroscience methods, vol. 134, no. 1, pp. 9-21, 2004.

[4] Prakash, A., Poulose, A., *Electroencephalogram-Based Emotion Recognition: A Comparative Analysis of Supervised Machine Learning Algorithms*, Data Science and Management, https://doi.org/10.1016/j.dsm.2024.12.004.